



Desenvolvimento de um agente autónomo para o jogo **tetris**



Inteligência Artificial


Possibilidades para uma peça

- Desenvolvemos uma função genérica que trata da identificação da peça atual, incluindo as suas possíveis rotações
- A partir do estado atual do mapa, calculamos todas as possibilidades de colocar a peça no mapa (simulando a sua queda para cada x) e guardamos todas essas opções numa lista.
- Por fim, submetemos todas essas possibilidades a várias funções de avaliação tendo em conta fatores de penalização e favorecimento




Possibilidades para a peça seguinte

- Inicialmente calculamos usamos o algoritmo de calculo de todas as possibilidades para a peça atual.
- De todas essas possibilidades, guardamos apenas metade das melhores jogadas para efeitos de otimização de tempo
- Com base nesses novos mapas que incluem a peça atual, recalculamos as possibilidades de jogar a peça seguinte em todos os seus possiveis estados.
- No fim, avalia todas essas possibilidades com as duas peças, escolhendo a melhor jogada através das mesmas avaliações, ficando no fim apenas com a posição ideal para jogar a peça atual do mapa.
- Este algoritmo é novamente calculado quando acabamos de jogar a peça atual e aparecem novas, dado que verificamos que é mais eficiente do que jogar de duas em duas peças.




Current piece



Next piece

Avaliações das jogadas



- Dado um mapa, reunimos um conjunto de fatores que favorecem e penalizam uma dada jogada.
 - **Altura total e máxima do mapa:** favorece jogadas onde a peça é colocada mais abaixo no mapa;
 - **Relevo:** favorece jogadas que não tornem o mapa muito irregular em termos de altos e baixos;
 - **Número de buracos:** penaliza jogadas que criem buracos;
 - **Número de linhas completas:** favorece jogadas que façam um numero maior de linhas completas;
 - **Número de colunas vazias:** penaliza jogadas que criem colunas altas de peças;
 - Após submetermos um mapa a estas avaliações, escolhemos o mapa com o menor valor total, indicando que possivelmente se trata da melhor jogada.
-

Otimização do algoritmo

- Para que o nosso agente faça o maior numero de pontos possível, é necessário que este calcule as possibilidades todas no menor intervalo de tempo para conseguir tomar decisões e jogar as peças. Para isso, implementamos soluções mais otimizadas para diminuir esse tempo de calculo.
- Uso de listas bidimensionais binárias (matriz) para determinar a ocupação de uma determinada coordenada do mapa de jogo.
- O cálculo das avaliações foi otimizado para esta nova representação matricial, reduzindo o numero de ciclos e operações de pesquisa.
- Uso de lookup tables para aceder a informação estática regularmente.
- Reduzimos o cálculo dos mapas possíveis para a metade quando o algortimo é de duas peças, em vez de calcular todas as possibilidades para duas peças.
- Alteração do comportamento do agente com base na velocidade atual e a altura do mapa, alternando entre o cálculo das possibilidades apenas para uma peça e para duas peças. Isto é, quando o jogo vai a alta velocidade e a altura do mapa não deixa concluir o calculo das possibilidades da peça atual e seguinte, alteramos apenas para calcular para a peça atual, o que é significativamente mais rápido, até conseguir diminuir novamente a altura do mapa.

The figure displays two 10x10 grids representing the state of a 2D cellular automaton at different time steps. The left grid shows the initial state, and the right grid shows the state after 100 generations. The cells are colored based on their value: 0 (white), 1 (red), 2 (green), 3 (blue), 4 (orange), and 5 (yellow). The initial state shows a small cluster of non-zero values in the bottom-left corner. After 100 generations, the cluster has grown significantly, spreading across the grid and forming a complex pattern.